



Introduction to Machine
Learning for Data Science

ПРОГНОЗУВАННЯ ВАРТОСТІ ГОТЕЛЬНИХ НОМЕРІВ

Підготував: Талаєвич Назар

ЗМІСТ

Вступ


Вибір Dataset-у


EDA

Feature Engineering

Порівняння обраних алгоритмів

Оцінка результатів та висновки





ВСТУП

Розробка ML-моделі для точного прогнозування середньої добової ціни (ADR) готельних номерів. Надання користувачам асистента Golobe можливості бачити очікувану вартість житла на етапі планування, що підвищує лояльність та конверсію сервісу.

Тип задачі

Регресія

Дані

Реальні дані
бронювань
(~119 000 записів)

Інструменти

Python, Scikit-learn,
Pandas, Matplotlib,
Seaborn.



ОБҐРУНТУВАННЯ ВИБОРУ ДАНИХ




Для навчання моделі було використано датасет, що базується на реальних операційних даних готелів (міських та курортних).

- * **Релевантність бізнес-моделі:**
Дані містять 32 ознаки
- * **Обсяг та репрезентативність:**
Вибірка з ~119 000 записів
- * **Чистота, структура та реальність ціноутворення.**



ЕКСПЛОРАТОРНИЙ АНАЛІЗ ДАНИХ (EDA)

Виявлення закономірностей та факторів, що мають найбільший вплив на ціноутворення (ADR).



Introduction to Machine Learning for Data Science

**"The laptop was
invented in 1981"
People in 1980:**



ПІДГОТОВКА ДАНИХ (FEATURE ENGINEERING)

Категорійні ознаки перетворюємо за допомогою One-Hot Encoding (`pd.get_dummies`). Числові ознаки масштабуємо для Linear Regression (`StandardScaler`). Відібрані ознаки, що мають найбільший вплив на ціну (на основі EDA та доменних знань):

hotel

reserved_room_type

lead_time

is_repeated_guest

arrival_date_month

stays_in_weekend_nights

stays_in_week_nights

market_segment

adults

children


babies



ПОРІВНЯННЯ ОБРАНИХ АЛГОРИТМІВ


Linear Regression

- Базовий метод
- Швидкий
- Інтерпретований
- Еталонний




Random Forest Regressor

- Точність на нелінійних даних
- Не потребує масштабування
- Стійкий до викидів



Gradient Boosting Regressor




- Найвища точність
- Виправлення помилок
- Гнучкість



ОЦІНКА РЕЗУЛЬТАТІВ ТА ВИСНОВКИ

Random Forest показав найкращий результат: MAE = 15.97 €, $R^2 = 0.760$. Gradient Boosting дещо поступається при стандартних гіперпараметрах. Linear Regression підтверджує гіпотезу про нелінійність залежностей у даних.

Порівняння метрик моделей



THANK YOU



He left
school



He left
school



If I left
school

